



Szeregi czasowe

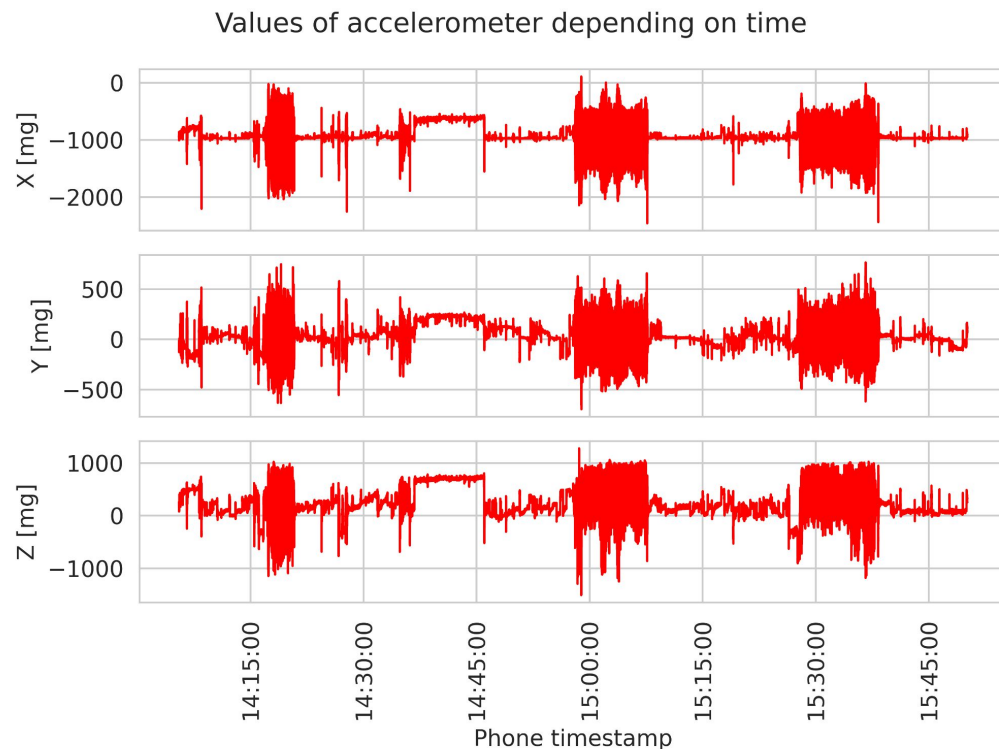
Wykład w ramach przedmiotu “Nauczanie maszynowe”
4 grudnia 2024

Kamil Książek

Uniwersytet Jagielloński

Szereg czasowy

Szeregiem czasowym nazywamy dane zawierające wartości w różnych taktach, najczęściej w równych odstępach czasu. Jeśli w każdym takcie występuje jedna wartość, mówimy o **jednowymiarowym szeregu czasowym** (ang. *univariate time series*), a jeśli wiele wartości, to o **wielowymiarowym szeregu czasowym** (ang. *multivariate time series*).



Zastosowania szeregów czasowych

- **ekonomia i finanse:** dane dot. bezrobocia, zajętości łóżek w szpitalach, kursów walut, cen akcji na giełdzie, itd.;
- **środowisko:** opady deszczu, jakość powietrza, itd.;
- **medycyna:** odczyty EKG, EEG, itd.



Dane giełdowe spółki Alphabet, źródło: CNBC

Zadania dot. szeregów czasowych

- **prognozowanie przyszłych wartości**
(ang. *forecasting*) na podstawie danych historycznych;
- **klasyfikacja;**
- **imputacja;**
- **wykrywanie anomalii**

i inne...



Prognoza danych finansowych firmy Apple przy
użyciu metody Prophet, źródło: h1ros.github.io

Rozkład szeregu czasowego

Jednym ze sposobów wyrażenia szeregu czasowego jest jego rozkład (**dekompozycja**) na kilka składowych:

- **trend $T(t)$** – długoterminowe przesunięcia średniej;
- **efekty sezonowe $S(t)$** – cykliczne fluktuacje związane z godzinami, dniami tygodnia, miesiącami, itd.;
- **cykle $C(t)$** – inne cykliczne fluktuacje (np. związane z cyklami biznesowymi);
- **rezydua $E(t)$** – inne losowe lub systematyczne fluktuacje.



Prognoza danych finansowych firmy Apple przy użyciu metody Prophet, źródło: h1ros.github.io

Rozkład szeregu czasowego

Najczęściej tworzy się osobne modele do każdej z tych składowych, a na koniec dodaje się je

$$X(t) = T(t) + S(t) + C(t) + E(t)$$

lub mnoży

$$X(t) = T(t) \cdot S(t) \cdot C(t) \cdot E(t).$$

Przyjrzymy się teraz rodzinie modeli **ARMA**, czyli autoregresywnej średniej kroczącej (ang. *autoregressive moving average*), a później przeanalizujemy model **Neural Prophet**.

Prognozowanie przy użyciu rodziny ARMA

$$\hat{X}(t) = \sum_{i=1}^N a(i) \cdot X(t-i) + \sum_{i=1}^M \theta(i) \cdot \epsilon(t-i),$$

gdzie

- $\epsilon(t) = X(t) - \hat{X}(t)$ jest błędem prognozowania,
- $\hat{X}(t)$ jest prognozą modelu dla kroku czasowego t ,
- $X(t)$ jest rzeczywistą wartością modelu dla kroku czasowego t ,
- N i M są hiperparametrami,
- $a(i)$ i $\theta(i)$ są wyuczonymi wagami związanymi ze znaczeniem wcześniejszych kroków czasowych.

Pierwsza suma dotyczy N przeszłych wartości szeregu czasowego (człon **autoregresywny**), a druga M przeszłych błędów prognozy.

Prognozowanie przy użyciu rodziny ARMA

- Model ARMA zakłada **stacjonarność** szeregu czasowego, czyli mającego stałe własności statystyczne w miarę upływu czasu.
- W przeciwnym wypadku może pomóc różnicowanie, które aproksymuje pochodną szeregu czasowego. Niech $X(t)$ będzie szeregiem czasowym mającym T obserwacji. Wówczas szereg

$$Y(t) = X(t) - X(t - 1), \quad t \in \{2, \dots, T\}$$

będzie posiadał $T-1$ obserwacji.

Prognozowanie przy użyciu rodziny ARMA

- Przeprowadzenie n rund różnicowania przybliży pochodną n -tego stopnia szeregu czasowego i eliminuje wielomianowe trendy do n -tego stopnia włącznie.
- **Autoregresywny zintegrowany model średniej kroczącej** (ang. *autoregressive integrated moving average*, ARIMA) przeprowadza n rund różnicowania, przybliżając stacjonarność szeregu, a następnie stosuje model ARMA.
- **Sezonowy model ARIMA** (ang. *seasonal ARIMA*, SARIMA) dodatkowo modeluje składową sezonową dla wybranej częstotliwości, np. tygodniowej, za pomocą techniki ARIMA.

Neural Prophet

- Przyjrzymy się teraz modelowi Neural Prophet zaproponowanemu w 2021 roku m.in. przez naukowców ze Stanforda oraz Facebooka [1]:

$$\hat{X}(t) = T(t) + S(t) + E(t) + F(t) + A(t) + L(t)$$

$T(t)$ – trend w chwili t ,

$S(t)$ – wpływ sezonowości w chwili t ,

$E(t)$ – wpływ zdarzeń i świąt w chwili t ,

$F(t)$ – wpływ zmiennych egzogenicznych na przyszłe predykcje,

$A(t)$ – wpływ autoregresji w chwili t w oparciu o przeszłe obserwacje,

$L(t)$ – wpływ opóźnionych obserwacji zmiennych egzogenicznych.

Modelowanie trendu w Neural Prophet

- Tradycyjne podejście do modelowania trendu polega na wyrażeniu go jako kombinacji tempa wzrostu k oraz przesunięcia m . Wówczas trend w czasie t_1 wyraża się poprzez przemnożenie tempa wzrostu z różnicą w czasie, zaczynając od punktu t_0 , wraz z przesunięciem o m .

$$T(t_1) = T(t_0) + k \cdot \Delta t = m + k \cdot (t_1 - t_0)$$

- W NeuralProphet trend może być modelowany jako funkcja odcinkowo liniowa, w której dobierane jest n_c punktów, pomiędzy którymi parametry zmiany tempa wzrostu są regularyzowane.

Modelowanie sezonowości w Neural Prophet

- Sezonowość w Neural Prophet jest modelowana przy pomocy **szeregów Fouriera**. Dla każdej sezonowości definiowane jest k składników sumy w szeregu o periodyczności p .

$$S_p(t) = \sum_{j=1}^k \left(a_j \cos\left(\frac{2\pi jt}{p}\right) + b_j \sin\left(\frac{2\pi jt}{p}\right) \right)$$

- Przykładowo, dla rocznej sezonowości, przy danych dziennych $p = 365.25$, zaś dla danych tygodniowych $p = 52.18$. Biblioteka automatycznie aktywuje dzienną, tygodniową i roczną sezonowość w zależności od zakresu i częstotliwości danych. Domyślnie, $k = 6$ dla sezonowości rocznej, $k = 3$ dla tygodniowej, a $k = 1$ dla dziennej.
- Szeregi Fouriera produkują gładkie funkcje, które są proste w interpretacji oraz stabilne w treningu. Niestety, modelują tylko **deterministyczną**, stałą w czasie sezonowość.

- Autoregresja (AR) jest procesem, w którym przyszłe wartości pewnej zmiennej zależą od jej przeszłych wartości. Liczba przeszłych wartości, do których sięgamy, odnosi się do rzędu p w modelu $AR(p)$. Współczynnik $\theta[i]$ jest modelowany osobno dla każdej wcześniejszej wartości.
- Niech c będzie punktem przesunięcia, $\epsilon[t]$ białym szumem. Wówczas:
$$y[t] = \sum_{i=1}^p \theta[i] \cdot y[t-i] + c + \epsilon[t].$$
- Parametr ten powinien być dobierany na podstawie przybliżonej długości istotnego kontekstu. W praktyce często jest to dwukrotność horyzontu prognozy h .

Modelowanie autoregresji – Deep AR

- Modelowanie autoregresji w Neural Prophet opiera się na AR-Net [2] i przyjmuje kilka wariantów. Jednym z nich jest **Deep AR**, w którym w tym celu trenowany jest perceptron wielowarstwowy.
- Dane jest p wcześniejszych obserwacji szeregu czasowego w wektorze $X \in \mathbb{R}^p$, a próbujemy przewidzieć kolejnych h wartości $Y \in \mathbb{R}^h$:

$$X = [Y[t - 1], Y[t - 2], \dots, Y[t - p]]$$

$$Y = [A^t[t], A^t[t + 1], \dots, A^t[t + h - 1]]$$

Modelowanie autoregresji – Deep AR

- Na wejście do sieci dane jest p ostatnich obserwacji. Sieć składa się z l warstw ukrytych o wymiarze d . Ostatnia warstwa ma na wyjściu h logitów **nieprzekształcanych funkcją aktywacji** oraz **pozbawionych wektora obciążenia** (ang. bias):

$$a_1 = \text{ReLU}(W_1 X + b_1)$$

$$a_i = \text{ReLU}(W_i a_{i-1} + b_i), \quad i \in \{2, \dots, l\}$$

$$Y = W_{l+1} a_l,$$

gdzie $b \in \mathbb{R}^d$, zaś rozmiar warstw ukrytych $W_i \in \mathbb{R}^{d \times d}, i \in \{2, \dots, l\}$, z kolei $W_1 \in \mathbb{R}^{d \times p}$ oraz $W_{l+1} \in \mathbb{R}^{h \times d}$.

Opóźniony regresor (ang. lagged regressor)

- Opóźnione regresory są zmiennymi, które wpływają na zmienną docelową w oparciu o ich własne wartości historyczne (opóźnione), a nie przyszłe wartości.
- Przykłady:
 - Zapotrzebowanie na energię w zależności od temperatury w poprzednich dniach.
 - Ceny jednych towarów w zależności od innych, np. ceny ropy z poprzednich kilku dni/tygodni.
- W Neural Prophet tworzony jest osobny moduł pod każdą z tych zmiennych towarzyszących i stosowany jest model AR-Net.

Przyszły regresor (ang. future regressor)

- Przyszłe regresory są dodatkowymi zewnętrznymi cechami, które wpływają na wartość przewidywanej zmiennej. W przeciwieństwie do opóźnionych regresorów, **ich wartości muszą być znane z góry (lub przewidziane)** dla wszystkich kolejnych kroków czasowych, dla których chcemy dokonać predykcji.
- Przykład: nadchodzące warunki pogodowe (temperatura, opady deszczu).

Wpływ wydarzeń i świąt

- Wybrane wydarzenia i święta, choć zachodzą sporadycznie, mają wpływ na wartość przewidywanej zmiennej.
- Mogą one zostać oznaczone zmienną binarną lub różnymi wartościami w przedziale $[t_e - n, t_e + m]$ wokół zdarzenia t_e przez $n + m$ dni. Przykładowo, przed świętami Bożego Narodzenia można ustawić okno $[-1, 0]$, dzięki któremu każdy kolejny dzień będzie miał wyrażony inny wpływ świąt na wynik.

- Jedną z częściej stosowanych metryk do oceny błędu regresji jest **pierwiastek błędu średniokwadratowego** (ang. *root mean square error*, *RMSE*):

$$RMSE(y, \hat{y}) = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2},$$

gdzie N jest liczbą próbek, y_i jest rzeczywistą wartością i -tej próbki, zaś \hat{y}_i predykcją modelu dla i -tej próbki.

Wśród innych można wymienić np. *mean absolute percentage error (MAPE)* lub *mean absolute deviation (MAD)*.

Tyle teorii, teraz spróbujmy zmierzyć się z rzeczywistym zbiorem danych i treningiem sieci neuronowej...

Źródła:

- G. E. P. Box i in., Time Series Analysis, Forecasting and Control, Fifth Edition, Wiley Series in Probability and Statistics, 2016.
- R. Weber, materiały do kursu szeregów czasowych, University of Cambridge, 2017.
- A. Geron, Uczenie maszynowe z użyciem Scikit-Learn, Keras i TensorFlow. Wydanie III, Helion, 2023.
- O. Triebe et al, NeuralProphet: Explainable Forecasting at Scale, arXiv 2111.15397, 2021.
- O. Triebe et al, AR-Net: A simple Auto-Regressive Neural Network, arXiv preprint 1911.12436, 2019.
- Dokumentacja Scikit-learn.